

**SVEUČILIŠTE JOSIPA JURJA STROSSMAYERA U OSIJEKU
FAKULTET ELEKTROTEHNIKE, RAČUNARSTVA I
INFORMACIJSKIH TEHNOLOGIJA OSIJEK**

Sveučilišni diplomski studij Računarstvo

**PRIMJENA DIFUZIJSKOG MODELA ZA
REKONSTRUKCIJU SLIKA KOMPRESIRANIH JPEG
ALGORITMOM**

Obrada slike i računalni vid

Antonio Mišević

Osijek, 2025.

SADRŽAJ

1. Uvod.....	1
2. Pregled područja i problematike	2
3. Pregled i opis skupa podataka.....	3
3.1. Zahtjevi skupa za dani problem	3
3.2. Odabrani skup i njegove pojedinosti.....	3
3.3. Podjela skupa i radnje nad podacima	4
4. Opis korištenog model i njegovih elemenata	5
4.1. Proces difuzije i difuzijski model.....	5
4.2. Konvolucijske neuronske mreže	6
4.3. U-Net i njegovi elementi.....	8
5. Treniranje mreže i rezultati	10
5.1. Implementacija modela	11
5.2. Hiperparametri i metrike mreže	12
5.3. Rezultati treninga.....	13
6. Zaključak	16
LITERATURA	17

1. Uvod

Super rezolucija (*engl. Super-Resolution - SR*) koncept je u sklopu strojnog učenja i računalnog vida koji obuhvaća različite metode i pristupe usmjerene ka poboljšanju kvalitete slike van njezinih početnih obilježja [1]. To zapravo znači da je uz pomoć valjanih metoda moguće ulaznu sliku male rezolucije pretvoriti u sliku povećane rezolucije, bitno je napomenuti kako nema garancije za potpunu preciznost rezultata odnosno ne mora biti potpuno jednaka originalu. Osim samog povećanja rezolucije metode je moguće koristiti i za uklanjanje određenih tipova šuma i drugih smetnji koje se nalaze na slici, što ovo područje čini veoma atraktivnim za istraživanje.

Ovaj rad bavit će se jednim od takvih problema uz oslonac na difuzijski model. Rad će objasniti difuzijske modele kao i njihov način rada. Ukratko će proći podatke koji su se koristili za treniranje model i njegovu strukturu i na kraju njegove rezultate.

2. Pregled područja i problematike

Super rezolucija slike aktualno je područje u sklopu umjetne inteligencije te je područje usmjereno ka obnovi ili povećanju rezolucije slike na temelju danog modela umjetne inteligencije. S obzirom da se radi o obradi slike prisutna je potreba za dobrim raspolaganjem računalnih resursa što je jedan od mogućih problema, ali puno veći problem leži u relativnosti rezultata. Odnosno za svaku sliku smanjenje rezolucije ili kvalitete može postojati nekoliko slika visoke rezolucije koje je moguće percipirati kao točan rezultat s obzirom da postoji nekoliko aspekata koji čine sliku, neki od njih su: boja, osvjetljenje, kontrast i slično. Napretkom dubokog učenja ova je problematika napredovala te je do sada oslonac bio na konvolucijskim mrežama, generativno zasnovanim mrežama (*engl. Generative Adversarial Networks - GANs*) te također difuzijskim modelima na kojima se temelji i sam rad. U zadnje vrijeme dodatna pažnja pridaje se transformatorima kao novom pristupu rješavanja problema u ovom području [2].

Difuzijski modeli kao jedna od korištenih metoda u sklopu super rezolucije ističu se po tome što daju bolje rezultate i povratnu informaciju od strane ljudi za generirane slike visoke rezolucije naspram generativnih mreža koje su prije njihove pojave bile dominantnije. Za rješavanje ovog rada odabran je model za difuzijski statističko uklanjanje šuma (*engl. Denoising Diffusion Probabilistic Models - DDPMs*), ali uz ovaj oblik također se koriste: generativni modeli zasnovani na ocjeni (*engl. Score-based Generative Models - SGMs*) i stohastičke diferencijalne jednačbe (*engl. Stochastic Differential Equations - SEDs*) [3].

3. Pregled i opis skupa podataka

U ovom poglavlju bit će opisan skup podataka koji se koristio, načini na koje je strukturiran kao i sadržaji koje je moguće vidjeti na slikama skupa te na kraju neke radnje koje je bilo potrebno obaviti nad skupom u skladu s danim problemom.

3.1. Zahtjevi skupa za dani problem


S obzirom da je cilj problema uklanjanje šuma i nepoželjnih elemenata na slici nastalih kao rezultat kompresije fotografije JPEG algoritmom poželjno je odabrati skup koji ima raznolik raspon sadržaja: od ljudi, životinja, biljaka, pejzaža, gradova i slično. Raznolikost slika također može pružiti uvid u aspekte obnove s kojima model ima problem. Radi jednostavnosti odabran je jedan od temeljnih skupova u području super rezolucije Div2K.

3.2. Odabrani skup i njegove pojedinosti

Div2K čest je i temeljan skup za probleme na području računalnog vida s obzirom da se sastoji od tisuću slika visoke rezolucije. Rezolucije slika nisu u potpunosti jednake, ali rasponi vrijednosti kreću se od 2000x1000 piksela, a prisutne su i neke slike kvadratnog oblika koje su dimenzija 2000x2000 piksela. Rezolucija i kvaliteta slika veoma je visoka što ih čini odličnom polaznom točkom za super rezolucija, a i sama raznolikost sadržaja na slikama zadovoljava tražene potrebe. Iako se navodi kako skup ima tisuću slika službena stranica s dokumentacijom kao i *Kaggle* ne prikazuju skupa za testiranje. Stranica s dokumentacijom o uputama za korištenje skupa već ima pripremljene slike niske rezolucije (*engl. Low Resolution - LR*) s određenim razinama smanjenja dimenzije koje idu do četiri puta [4] [5].

3.3. Podjela skupa i radnje nad podacima

Moj odabir podjele skupa podatak bio 700 slika za trening i po 100 slika za validacijski i testni skup što je približno jednako 80/10/10 podjeli podataka. S obzirom da zadatak ne traži smanjenje rezolucije nego obnovu kvalitete slike nastale kompresijom korištenjem JPEG algoritma nije postojala potreba za smanjenjem rezolucije. U svrhu uvjeta sličnijih stvarnim okolnostima gdje je teško moguće dobiti podjednake slike s podjednakom razinom kvalitete bilo je potrebno odabrati nekoliko razina kvalitete. U sklopu *python* biblioteka *cv2* ili *Pillow* biblioteke dostupne su već implementirane funkcije za kompresiju te je samo potrebno predati razinu kvalitete. Odabrane razine kvalitete iznosile su 10, 30 i 50%. Bitno je napomenuti kako razina kvalitete označava koliko će kvalitetna slika ostati te je obrnuto razini kompresije, u konkretnom primjeru slike s razinom kvalitete od 10% izgledale su najoštećenije naspram druge dvije kategorije. U sklopu projekta također je korištena još jedna dodatna metoda koja je poprilično popularna u kontekstu super rezolucije. U pitanju je skraćivanje (*engl. cropping*), radi se o metodi uzimanja segmenta potrebnih dimenzija koji je uglavnom manji od ukupne veličine slike, u slučaju ovog problema radilo se o dimenzijama 256x256 piksela. Kako je sama slika puno veća od potrebnog segmenta proces je moguće ponavljati i na taj način dobiti puno veći broj fotografija u odnosu na pravi broj fotografija u podatkovnom skupu. Ova metoda može se svrstati kao dio šireg termina za dobivanje većeg broja podataka. Metoda je dosta česta u sklopu strojnog učenja, a radi se o doradivanju (*engl. augmentation*). Metoda pruža mogućnost pravljenja novih podataka obavljanjem određenih transformacija na osnovnoj slici. Neke od glavnih su: invertiranje, rotacija, povećavanje, smanjivanje i slično. Na taj način se nadopunjuje broj različitih verzija slike što može poboljšati generalizacijske sposobnosti modela. Slika [3.1](#) prikazuje neke od osnovnih metoda.



Sl. 3.1: Neke od osnovnih metoda augmentacije

4. Opis korištenog model i njegovih elemenata

4.1. Proces difuzije i difuzijski model

Difuzija kao koncept poznata je više u kontekstu kemije te označava postupak kretanja molekula iz područja veće gustoće u područje manje gustoće. Način rada difuzijskih model konceptualno je povezan s postupkom difuzije. Naime isto kao što biološki proces kretanja čestica nije trenutačan nego se odvija tokom vremena tako je i u ovim modelima postupak dodavanja šuma iterativan odnosno odvija se

postepeno. Taj iterativni dio dodavanja šuma usko je povezan uz difuzijske modele te ih ujedno odvaja od generativnih modela po načinu rada.


Postupak difuzije u modelima obuhvaća iterativno dodavanje šuma slici kroz određeni broj koraka te je bitan aspekt kako postupak dodavanja šuma uglavnom prati neka određena pravila ili statističku distribuciju. U prolasku kroz iteracije unaprijed šum se postepeno dodaje te se događa prijelaz iz normalne slike bez šuma u potpuni šum odnosno više nema naznaka originalne slike. Postupak povratak obrnut je postupku prolaska kroz iteracije te također iterativno uklanja šum na osnovu izračuna ili dane distribucije koju šum slijedi što modelu daje uvid u način na koji se šum ponaša i nastaje te ga tako uči ukloniti.

Difuzijski modeli uglavnom prate ovu logiku, razlike su jedino u načinu na koji se to realizira, u drugom poglavlju navedena su tri osnovna tipa difuzijskih modela. Rješenje ovog problema zasnovano je na modelu difuzijski statističkog uklanjanja šuma (DDPM) te ćemo njega u nastavku objasniti. Ovaj tip difuzijskog model oslanja se na dva Markovljeva lanca koji zapravo opisuju statističke prijelaze svih mogućih stanja u skupu ukupnih događaja. Oslanja se na neki predefinirani oblik distribucije, uglavnom se radi o Gaussovoj iako nije jedina opcija, za definiranje prijelaza stanja. Obrnuti postupak oslanja se na distribuciju koja je odabran sa svrhom izučavanja načina na koji se šum dodaje i koja pravila prati dodavanje šuma [3].

4.2. Konvolucijske neuronske mreže

Konvolucijske neuronske mreže (*engl. Convolutional Neural Networks - CNN*) vrsta su neuronskih mreža čija je svrha usmjerena ka obradi podataka s prostornim rasporedom te se iz tog razloga vrlo često koriste u kontekstu obrade slike i računalnog vida. Osmišljene su na način da pokušavaju imitirati vizualni sustav sisavaca gdje se informacije primaju postepeno, u slojevima. Prostorni raspored slojeva omogućuje da svaki sloj bude zadužen za određene elemente i značajke slike.


Sam postupak obuhvaća prolazak predefiniranog filtera po elementima tj. pikselima slike, obavlja se pripadni proračun i kao rezultat dobivamo mapu značajki. Odabirom određenog tipa filtera moguće je usmjeriti mrežu prema određenim značajkama sa slike. Primjer jednostavnog procesa konvolucije vidljiv je na slici [4.2](#).



Sl. 4.2: Primjer procesa konvolucije

Postupak konvolucije uglavnom je popraćen postupkom aktivacije koristeći neku od mogućih aktivacijskih funkcija, uglavnom se radi o: Sigmoid, Tanh i ReLU funkcijama iako postoje i druge.

Nakon toga slijedi sloj sažimanja koji za svrhu ima smanjenje prostorne dimenzije podataka te se na taj način uklanjaju manje bitne značajke, ali se također smanjuje memorijska zahtjevnost problema s obzirom da je potrebno obraditi manji broj podataka. Postoji nekoliko kriterija po kojima se sažimanje obavlja, jedan od osnovnih je sažimanje po maksimalnoj vrijednosti, u tom obliku sažimanja kao preostala vrijednost iz određenog segmenta uzima se najveća vrijednost u tom segmentu. Koncept sažimanja vidljiv je na slici [4.3](#).




SI 4.3: Primjer operacije sažimanja

Prije samih izlaznih vrijednosti odnosno rezultata podaci se predaju potpuno povezanoj neuronskoj mreži s pripadnom arhitekturom ovisnom o naravi problem koji se pokušava riješiti.

4.3. U-Net i njegovi elementi

U-Net arhitektura jedna je od najkorištenijih arhitektura u kontekstu obrade slike i računalnog vida te je i sama nastala u svrhu segmentacije medicinskih slika. Naziv arhitekture dolazi zbog oblika mreža koji nalikuje na slovo U. Arhitektura i oblik mreže vidljivi su na slici [4.3](#).



Sl. 4.3: Prikaz arhitekture U-Net mreže

Struktura mreže sastoji se od enkodera, uskog grla (*engl. bottleneck*) i dekodera. Enkoder je silazni dio mreže te se u tom dijelu mreže obavlja dohvaćanje značajki kao i smanjenje dimenzije, broj filtera odnosno slojeva mreže raste svakim idućim korakom na putu do uskog grla što omogućuje sve opsežnije dohvaćanje značajki. Svaka stepenica sastoji se od konvolucijskog sloja popraćenog sa slojem sažimanja.

Usko grlo smanjuje dio koji dobije kao rezultat enkodera to preostaju samo temeljni elementi i značajke slike.

Dekoder zatim rekonstruira sliku postupkom transponirane konvolucije, svaka razina ponovno raste u dimenzijama te se oslanja na podatke iz uskog grla odnosno prijašnje razine dekodera. Dodatnu pomoć u procesu rekonstrukcije pružaju veze za preskakanje (*engl. skip connections*) koje održavaju određene detalje i elemente iz svake razine enkodera te ih predaju dekoder u svrhu bolje rekonstrukcije slike i njezinih detalja [6].

5. Treniranje mreže i rezultati

U prijašnjem poglavlju objašnjena je U-Net arhitektura kao i njezini elementi, a u poglavljima prije tog objašnjeni su difuzijski model kao i ukratko objašnjenje konkretnog model koji će se koristiti.

Glavna referenca za strukturu mreže i modela dostupno je na [\[7\]](#). Rad koristi navedene metode za usporedbu s generativnim mrežama koje su također konkurentne u području super rezolucije. Kao i ovaj rad navedeni rad cilja ka obnovi slika sa raznolikim sadržajima: od ljudi i lica do biljaka prirode i slično. Za razliku od navedenog rada koji se temelji na obnovi rezolucije slike za određene razine ovaj rad usmjeren je ka rekonstrukciji šuma nastalog kao produkt kompresije slike JPEG algoritmom.

5.1. Implementacija modela

Rješenje samog modela kao i svih njegovih aspekata implementirana je u programskom jeziku python-u uz pripadajuće biblioteke i module potrebne za realizaciju rješenja. S obzirom da je dodavanje šuma iterativno kroz t vremenskih koraka potrebno je implementirati funkciju za dodavanje vremenske zavisnosti. Dodatno proširenje vremenske zavisnosti i modeliranja dodano je i u blokove mreže pomoću FiLM metoda (*engl. Feature-wise Linear Modulation*) koja se u novijim radovima sve češće uvodi ne samo u enkoderskom dijelu mreže već kroz cijelu tako da je vremenski aspekt i zavisnost uvedena na taj način, dok je samo modeliranje vremena postignuto pomoću sinusnog upisivanja (*engl. Sinusoidal Embedding*) čime se diskretni vremenski koraci difuzije pretvaraju u kontinuiranu vremensku domenu za predaju modelu.

Što se samog pristupa tiče s obzirom da se radi od DDPM difuzijskom modelu koji je ukratko objašnjen u četvrtom poglavlju. Potrebno je odabrati statističku distribuciju po kojoj će se šum dodavati i odrediti vremenski oblik koji će definirat vremenske korake unutar kojih će slika preći u stanje potpunog šuma. S obzirom da je Gaussova distribucija osnovna te garantira bolju obnovu, ista je i odabrana, a za vremenski aspekt odabran je kosinusni raspored (*engl. Cosine Scheduling*) koji omogućuje manje razine šuma u ranijim koracima postupka kako proces učenja ne bi bio dodatno otežan [8].

Uz standardne elemente U-Net mreže proširenje je napravljeno u sklopu dodatnog ResNet bloka koji se u praksi koriste za dodavanje veza između blokova za smanjenje gubitaka između razina mreže. Uz rezidualnu funkciju za smanjenje gubitaka koja se provodi na kraju bloka dodane su i ove funkcije u navedenom redoslijedu: 1. normalizacija ulaza – normalizira ulaze kako bi sve bilo u sličnijem rasponu vrijednosti i na taj način lakše za proces učenja i baratanja podacima. 2. aktivacija – nakon normalizacije koristi se swish odnosno silu aktivacijska funkcija koja je veoma pogodna u kontekstu difuzije. 3. konvolucijski sloj – obavlja postupak konvolucije s postavkama kao i u ostatku mreže, radi se o kernelu dimenzije 3x3 sa

pomakom jednakim 1 (*engl. stride*), nadopuna (*engl. padding*) postavljena je na postavku jednake nadopune (*engl. same*). 4. Vremenska formulacija i zavisnost - korištenje FiLM metode koja je navedena i objašnjena u početku poglavlja. Nakon ovoga ponavljaju se koraci od 1. do 3. uz dodatak bloka za izbacivanje neurona (*engl. dropout*) sa vrijednosti od 40%, svrha je nasumično izbacivanje neuron u povremenim trenucima treniranja kako bi se uklonilo oslanjanje na specifične neuron i na taj način smanjila vjerojatnost pretjerane usklađenosti (*engl. overfitting*). Na kraju ide rezidualni dio bloka koji nadodaje prijašnje ulaze rezultatu svega što je dosad navedeno. Redoslijed broja filtera u enkoderu i dekoderu je: 64-128-256-512 te obrnuto za dekodeer.


5.2. Hiperparametri i metrike mreže

Struktura mreže kao i difuzijskog modela navedeni su u prethodnim dijelovima ovog poglavlja. U ovom dijelu dotaknuti ćemo se ostalih parametara koji su definirali proces treniranja. U poglavlju koje se bavi podacima napomenuto je da su podaci podijeljeni u omjeru približno 80/10/10 gdje je 80% podataka korišteno za trening, a po 10% za validaciju i testiranje. Razine kvalitete korištene za JPEG algoritam iznosile su: 10, 30 i 50%. Rezolucija predanih slika iznosila je 256x256 piksela. Broj koraka po svakoj epohi iznosi je 1000 odnosno svaka epoha sastojala bi se od 1000 serija (*engl. batch*) dok je veličina serije bila postavljena na 32. Broj koraka korišten u procesu dodavanja i uklanjanja šuma iznosio je 1000, broj epoha iznosio je 100, iako je obavljen postupak ranog zaustavljanja s obzirom da vrijednosti gubitaka nisu pokazivale značajan napredak nakon 40-te epohe, trening je zaustavljen na 60-toj epohi. Za funkciju gubitka korištena je prosječna apsolutna greška (*engl. Mean absolute error - MAE*), dok je metoda za poboljšanje parametara bila Adam uz stopu učenja 0.0001 odnosno $1e^{-4}$. Osim navedene metrike za gubitak također su korištene još dvije metrike: index sličnosti strukture (*engl. Structural similarity index - SSIM*) koja promatra sličnost strukture slika u tri aspekta: svjetlina, kontrast i struktura. Rezultat metrike može biti u rasponu vrijednosti od -1 do 1 gdje je 1

potpuna sličnost, a -1 potpuna razlika. Osim nje korištena je i metrika vrhunac omjera signala i šuma (*engl. Peak signal-to-noise ratio - PSNR*) pod signalom misli se na originalnu sliku dok je šum izobličenje na slici, što je vrijednost metrike veća to je rezultat bolji, a za izračune se oslanja na srednju kvadratnu pogrešku (*engl. Mean-squared error*) piksela na slici.


5.3. Rezultati treninga

Iako je originalni plan treninga trebao biti 100 epoha trening je prekinut nakon 60-te epohe, iako pretjeranih napredaka u metrikama i rezultatima nije bilo već nakon 40-te epohe. Iz procesa treninga i vizualnih rezultata vidljivo je kako model obavlja neki proces učenja te je vidljivo poboljšanje u rezultatima, kako numeričkim tako i vizualnim. Bitna stvar za napomenuti je kako je jedna od odabranih razina kvalitete, a radi se o 10% možda već sama po sebi van opsega i mogućnosti obnove iz razloga što modeli generalno neće biti u stanju obnoviti podatke i detalje koji su nestali u procesu kompresije tako da bi rezultati i metrike moguće bile i bolje. U nastavku će biti prikazani neki vizualni rezultati s pripadnim metrikama u kontekstu računalnog vida, kratki osvrt i tumačenje. U svrhu razumijevanja terminologije: LR označava sliku niske rezolucije nastale JPEG kompresijom, SR je slika koja je rezultat modela, dok je HR slika visoke rezolucije odnosno originalna slika.




Sl. 5.4: Rezultati nakon 10-te epohe treninga

Prosjek PSNR: 13.3959, Prosjek SSIM = 0.1429



Sl. 5.5: Rezultati nakon 20-te epohe treninga

Prosjek PSNR: 14.1428, Prosjek SSIM: 0.2847



Sl. 5.6: Rezultati nakon 30-te epohe treninga

Prosjek PSNR: 16.4487, Prosjek SSIM: 0.3936



Sl. 5.7: Rezultati nakon 40-te epohe treninga

Prosjek PSNR: 15.8569, Prosjek SSIM: 0.5170

Iz rezultata je vidljiv napredak u vizualnom smislu iako su prisutne manjkavosti i šum, metrika za sličnost strukture slika nastavlja rasti dok sličnost na razini piksela također pokazuje trend rasta, ali poprilično slabije iako je za očekivati nešto slično s obzirom na navedenu premalu razinu kvalitete što onemogućuje obnovu svih piksela.

6. Zaključak

Iz rezultata koji su prikazani vidljiva je prisutnost procesa učenja i napretka rezultata kako u obliku numeričkih metrika, a tako i u vizualnom smislu. Prostor za napredak i poboljšanje modela je vidljiv te bi uz određena poboljšanja rezultati moguće bili puno bolji.

Zahtjevnost i izazovi područja obrade slike i računalnog vida, a tako i super rezolucije su jasni te je potrebna visoka razina pozadinskog znanja i razumijevanja ako postoji težnja za dobrim rezultatima. S druge strane prisutna je i ograničenost ljudskih osjetila koja kao i subjektivnost onemogućuje apsolutnost rezultata.

No međutim sam problem pruža mogućnosti i ideje o uštedi resursa te se iz tog razloga čini uzbudljivim za nadogradnju i uz sve prisutne izazove i poteškoće.

Sam rad pružio je uvid, temeljne koncepte i znanja na području strojnog učenja i umjetne inteligencije kao najopsežnijeg termina pa zatim za obradu slike i računalnog vida, super rezolucije slike i difuzijske modele. Prikazuje kako je čak i uz jednostavnije pristupe moguće postići pristojne rezultate, a sama priroda problema i područja uvijek ostavlja još prostora za poboljšanje i napredak.

LITERATURA

[1] “Super Resolution” Science Direct [Online]. Dostupno na:

<https://www.sciencedirect.com/topics/computer-science/super-resolution>

[2] D. Duttu, “State-of-the-Art Transformer Models for Image Super-Resolution: Techniques, Challenges, Applications,” Arxiv. Dostupno na: <https://arxiv.org/abs/2501.07855> (pristupljeno 22. rujna 2025.)

[3] B. B. Moser, “Diffusion Models, Image Super-Resolution And Everything: A Survey,” Arxiv. Dostupno na: <https://arxiv.org/abs/2401.00736> (pristupljeno 22. rujna 2025.)

[4] Div2K Dataset - službena dokumentacija. Dostupno na: <https://data.vision.ee.ethz.ch/cvl/DIV2K/> (pristupljeno 10. srpnja 2025.)

[5] Div2K High Resolution Images – Kaggle stranica za pristup skupu podataka. Dostupno na: <https://www.kaggle.com/datasets/soumikrakshit/div2k-high-resolution-images> (pristupljeno 10. srpnja. 2025)

[6] U-Net Architecture Explained [Online], GeeksForGeeks, dostupno na: <https://www.geeksforgeeks.org/machine-learning/u-net-architecture-explained/>

[7] C. Saharia, “Image Super-Resolution via Iterative Refinement,” Arxiv. Dostupno na: <https://arxiv.org/abs/2104.07636> (pristupljeno 12. srpnja 2025.)

[8] A. Nichol, “Improved Denoising Diffusion Probabilistic Models,” Arxiv. Dostupno na: <https://arxiv.org/abs/2102.09672> (pristupljeno 23. rujna 2025.)